

MemoryBank: Enhancing Large Language Models with Long-Term Memory

AAAI 2024

汇报人: 杨嘉松

班级: 信安232

学号: U202342613

MemoryBank: Enhancing Large Language Models with Long-Term Memory

AAAI 2024



作者

Wanjun Zhong, Lianghong Guo, Qiqi Gao, He Ye, Yanlin Wang



单位

Sun Yat-Sen University / Harbin Institute of Technology /
KTH Royal Institute of Technology

一句话概括

本文提出 MemoryBank，为大语言模型构建外部长期记忆系统，使其能够存储、检索、更新记忆，并逐步形成用户画像，从而提升长期交互能力。



主题：LLM 长期记忆机制 / AI Companion / 持续个性化交互



MemoryBank

记忆存储 (Memory Storage)



历史对话

按时间存储用户与模型的对话记录



事件摘要

关键事件与偏好摘要 (如送礼、出行等)



用户画像


用户的偏好、性格与行为特征



记忆更新 (Memory Updating)



记忆强度更新



艾宾浩斯遗忘曲线



相关记忆
与当前查询最相关的
记忆片段



用户画像
基于长期交互形成的
用户认知



事件摘要
对关键事件的结构化
总结与记录



SiliconFriend

输入构建 (Memory Augmented Prompt)

相关记忆
Relevant Memory

用户画像
User Portrait

事件摘要
Event Summary

记忆增强

历史对话 (History)

明天是我女朋友的生日。



你应该准备礼物 ...

...

记忆检索

当前查询 (Query)

发送

你还记得她喜欢的礼物吗？

1. 研究问题：LLM 缺什么？

核心问题：现有大语言模型擅长生成与理解，但缺乏真正的长期记忆能力。

❓ 问题表现

- 1 对话一长就遗忘早期信息，难以保持连续上下文
- 2 无法稳定记住用户偏好、经历与情绪变化
- 3 每次交互都像重新开始，个性化程度不足
- 4 缺乏对长期关系与长期任务的持续支持

★ 为什么重要？



AI 伴侣

需要记住用户经历
与关系脉络



心理陪伴/咨询

需要跟踪情绪状态
与历史事件



秘书助手

需要记住偏好、日程
与长期任务



一句话理解

论文关注的是：如何让 LLM 在长期交互中既能记住过去，又能据此做出更连续、更个性化的回应。

2. 以往工作的假设与局限

以往工作的典型思路



- 1 短期上下文拼接**
把更多历史对话放进 prompt



- 2 长上下文窗口**
依赖更长输入长度维持记忆



- 3 记忆增强网络**
如 MANN / NTM 等外部记忆结构



- 4 长对话数据集**
训练模型处理更长轮次对话



这些思路的隐含假设与不足



- 默认：历史放得更多，模型就会自然记住
- 但：上下文成本高，且并不等于稳定长期记忆



- 默认：记忆只是“保存”，而不是“更新”与“遗忘”
- 但：缺少用户画像，无法形成持续个性理解



已有长对话研究往往轮次有限，不足以覆盖真正的长期陪伴场景



难以兼顾记忆检索、结构化摘要与类人记忆更新



作者的批判

问题不在于“历史不够长”，而在于缺少一个可存储、可检索、可更新、可画像的长期记忆系统。

3. 论文的新见解与贡献



新见解： LLM 的长期记忆不必完全依赖参数更新，而可以通过外部 **MemoryBank** 以**非参数化**方式实现。



贡献 1：长期记忆机制

提出 MemoryBank，使模型能够存储、召回、更新记忆，并形成用户画像。



贡献 2：系统落地

构建 SiliconFriend，将 MemoryBank 应用于长期 AI 伴侣场景。



贡献 3：泛化性

支持开源与闭源模型，支持中英文，并可带或不带遗忘机制。

与以往方法的本质区别



记忆不只是历史对话



还包含事件摘要



还包含用户画像




还包含遗忘与强化



MemoryBank 把“长期记忆”从上下文工程，提升为一个完整的外部记忆系统设计问题。

4. 技术概述：MemoryBank 整体框架



三层结构 + 一次增强： 存储—检索—更新，最终服务于长期交互中的回答生成。

5. 技术细节 I：存储与检索

Memory Storage: 记忆存什么？



详细历史对话

多轮对话按时间戳保存，保留细节



分层事件摘要

每日摘要 → 全局摘要，提炼关键事件与偏好



动态用户画像

每日画像 → 全局画像，概括性格、情绪与行为倾向



这使记忆既有细节层，也有抽象层。

Memory Retrieval: 怎么取出来？

1

101
010
101

把每个记忆片段编码为向量



2



用 FAISS 建立索引



3



把当前对话编码为 query



4



检索最相关 memory pieces



5



与用户画像、事件摘要一起拼入 prompt



本质上


它把长期记忆召回问题转化为一次稠密检索任务。

6. 技术细节 II: 记忆更新与遗忘机制



灵感来源：艾宾浩斯遗忘曲线

人类记忆会随时间自然衰减，但在被重新回忆后会得到强化。



艾宾浩斯遗忘曲线：在没有进一步复习的情况下，记忆保留程度随时间指数级下降；每次回忆都会提升记忆强度，减缓遗忘。



遗忘曲线的数学表达（指数衰减）

$$R = e^{-t/S}$$

R ：记忆保留程度

t ：距离上次学习/召回的时间

S ：记忆强度



记忆更新规则（Memory Updating）

- 1 新记忆第一次出现时，初始化 $S = 1$
- 2 随着时间推移，记忆保留程度按指数衰减
- 3 若记忆再次被召回，则 $S = S + 1$ ，并把 t 重置为 0



含义：越重要、越近期、越常被提及的记忆，会被保留得更久；不重要且久未召回的记忆，会逐渐淡化。



作者也承认该模型是探索性的、简化的类人记忆模拟。

7. SiliconFriend: 系统落地与定性验证

系统构建

1 阶段 1:

对开源模型做心理对话微调
(38k 对话, LoRA)



2 阶段 2:

接入 MemoryBank,
获得长期记忆与用户画像能力



支持的模型基座

ChatGPT / ChatGLM / BELLE

中英双语

心理陪伴

相比基线, 回复更有共情、
更能提供建设性支持



用户

我最近和女朋友分手了,
感觉很难受, 不知道怎么办。



SiliconFriend

听起来你现在很难过, 我很理解。
失去一段关系确实会让人痛苦。
你不是一个人, 我会在这里陪着你。
我们可以慢慢聊聊你的感受,
也可以一起想想让你好受一些的方式。
你愿意先从哪方面说起呢?



基线模型

感情问题比较复杂, 时间会
慢慢帮你解决, 建议转移注意力。

记忆召回

能记住曾推荐的 Python 书名,
也能判断没做过堆排序



用户

我想学习 Python,
你之前推荐过什么书来着?



SiliconFriend

你之前问过这个问题,
我推荐过《Automate the Boring
Stuff with Python》,
非常适合入门哦!



用户

我们一起写过堆排序吗?



SiliconFriend

没有哦, 我们之前一起写过
快速排序, 但没有写过堆排序。

个性化交互

能依据不同用户画像
给出不同活动建议



Linda: 内向、重视个人成长

Linda

周末有什么活动建议吗?



SiliconFriend

可以去博物馆或艺术展,
或者参加烹饪课学习新技能,
这些活动更适合喜欢安静
和自我提升的你。



Emily: 外向、好奇心强

Emily

周末有什么活动建议吗?



SiliconFriend

可以尝试户外徒步、音乐会
或者参加社交活动, 认识
新朋友、体验新鲜事物
会让你更充实快乐!



定性结果说明: MemoryBank 不只提升“记住了什么”, 也影响“如何回应用户”。

8. 实验设计与定量结果

实验设置



10 天对话记忆库



15 个虚拟用户



约 450 个话题



194 个 probing questions (中英各 97)

• 评估指标 •

RA: 检索准确率

Cor: 回答正确性

Coh: 上下文连贯性

Rank: 综合排序得分

主要结果

语言	模型	RA 检索准确率	Cor 回答正确性	Coh 上下文连贯性	Rank 综合排序得分
英文 (En.)	SiliconFriendChatGLM	0.809	0.438	0.680	0.498
	SiliconFriendBELLE	0.814	0.479	0.582	0.517
	SiliconFriendChatGPT	0.763	0.716	0.912	0.818
中文 (Ch.)	SiliconFriendChatGLM	0.840	0.418	0.428	0.510
	SiliconFriendBELLE	0.856	0.603	0.562	0.565
	SiliconFriendChatGPT	0.711	0.655	0.675	0.758

1

ChatGPT 版本整体最好，说明框架有效。

2

开源模型也有较高检索准确率，说明机制具有泛化性。

3

不同模型在中英文上的优势不同。

9. 影响、批判与未来工作



论文影响

- 把 LLM 长期记忆从“上下文拼接”提升为“外部记忆系统设计”问题
- 强调记忆应同时包含：
存储、检索、摘要、画像、更新
- 对后续 Agent memory、
RAG memory、个性化助手设计有启发



我认为的局限

- 遗忘机制较为简化，只用离散记忆强度 S 描述复杂认知过程
- 大量实验依赖 ChatGPT 模拟用户，
真实长期用户验证仍偏少
- 缺少更强基线对比，如更系统的
RAG/长上下文方法
- 未充分讨论隐私、安全、错误记忆污染
等现实问题



未来可改进方向

- 更精细的记忆管理：
重要性、置信度、来源追踪
- 用户可控的遗忘与隐私机制
- 更长时间跨度、更真实的人类
长期交互评测
- 把记忆与规划、反思等
Agent 模块进一步结合



总结：MemoryBank 的价值不只是“让模型记住”，更在于把“如何记、记什么、何时忘、如何用”系统化。

谢谢！

·

敬请指正

· Q&A ·